ECONOMETRIA FÁCIL

Como eu projetei uma eleição: modelo linear e priors

Victor Rangel

Antes: previsão a priori. Com votos: estimação por WLS.

Antes da primeira urna do segundo turno, o que dá para prever com o primeiro turno e uma pesquisa de transferência? E quanto a previsão muda quando começam a chegar os votos? Eu montei este exercício com uma **estrutura linear de previsão nas duas etapas**: antes, uso priors para os coeficientes; depois, estimo esses coeficientes com os primeiros votos.

Com zero urnas, a simulação com priors informados pela Quaest e minhas hipóteses de participação produziu média de 49,47% dos válidos para Lula. Ele passou de 50% em 3.463 dos 10.000 cenários, ou 34,63%. Depois, estimei a regressão sem prior com cerca de 1% das seções nacionais apuradas: a média foi de 51,67%. No corte complementar de cerca de 2%, ficou em 51,65%. O resultado doméstico final foi 51,78% e entrou somente na avaliação.

Com zero urnas, uso um modelo linear com priors. Sorteio coeficientes informados pela Quaest e pelas hipóteses de participação, aplico cada matriz ao primeiro turno e obtenho a distribuição das projeções. Essa é a previsão a priori do modelo: seus coeficientes ainda não foram ajustados a votos observados do segundo turno. **Depois das primeiras urnas, estimo os coeficientes por WLS sem prior.** As explicativas X e as respostas observadas Y permitem esse ajuste; os 600 resultados posteriores vêm de bootstrap municipal. A expressão "modelo linear descreve a relação de previsão; "estimação descreve como obtenho os coeficientes.

A implementação é minha, inspirada na explicação de Rodrigo Mahlmeister, cujo código original não foi recuperado. Fiz uma reconstrução retrospectiva: já conhecia o resultado final durante a investigação, e a escolha entre especificações ocorreu nesse contexto. Os votos posteriores a cada corte ficaram fora do respectivo ajuste. Os placares projetados se referem ao Brasil sem exterior; os cortes de 1% e 2% medem a totalização nacional de seções, que inclui o exterior. No carrossel, apresento o corte de 1%; aqui detalho também o de 2%.

Revisão editorial v30. Esclareci o uso do modelo linear com priors antes das urnas, sem alterar os resultados. Preservei o backtest parcial de 2014, 2018 e 2022 e a proteção histórica para as faixas, apresentados na v29. Essa proteção não transforma frequências de cenários em probabilidades calibradas.

1. A estrutura linear de previsão

Minha unidade de observação é a **seção eleitoral**. Especifico uma relação linear entre o perfil do primeiro turno e os votos previstos para o segundo. Essa estrutura já é usada antes da apuração, com coeficientes probabilísticos informados por priors. Quando observo votos do segundo turno, ajusto os coeficientes por regressão ponderada e represento o que a relação não explica por um termo de erro.

Usei os arquivos do TSE de 2026. O universo projetado contém 497.897 seções no Brasil, sem exterior, e os resultados agregados que apresento se referem a esse universo doméstico.

Para evitar ambiguidade, o índice i identifica a seção; os sobrescritos (1) e (2), o primeiro e o segundo turno; e $[s]$, o cenário. O conjunto de origens é $\mathcal{G} = \{L, F, O, BN, A\}$. O denominador N_i continua sendo o eleitorado apto do primeiro turno.

Para cada seção i, chamo de N_i o número de eleitores aptos no primeiro turno e divido esse eleitorado em cinco grupos de origem, identificados por g:

Origem g	Contagem no primeiro turno	Variável explicativa
L - Lula	$L_i^{(1)}$	$x_{iL} = L_i^{(1)}/N_i$
F - Flávio	$F_i^{(1)}$	$x_{iF} = F_i^{(1)}/N_i$
O - Outros candidatos	$O_i^{(1)}$	$x_{iO} = O_i^{(1)}/N_i$
BN - Branco/nulo	$BN_i^{(1)}$	$x_{iBN} = BN_i^{(1)}/N_i$
A - Ausências	$A_i^{(1)}$	$x_{iA} = A_i^{(1)}/N_i$

Essas contagens somam os aptos. Portanto, as cinco explicativas são proporções que somam um:

$$\begin{aligned} N_i = L_i^{(1)} + F_i^{(1)} + O_i^{(1)} + BN_i^{(1)} + A_i^{(1)}, \\ \sum_{g \in \mathcal{G}} x_{ig} = 1. \end{aligned} \tag{1}$$

Incluir brancos/nulos e ausências mantém a participação eleitoral dentro do modelo. Quem faltou no primeiro turno pode comparecer no segundo; quem votou pode faltar ou deixar de produzir um voto válido.

Nas seções já apuradas no segundo turno, observo $L_i^{(2)}$ e $F_i^{(2)}$, os votos de Lula e Flávio. As duas variáveis resposta que uso no ajuste são:

$$y_{iL} = \frac{L_i^{(2)}}{N_i}, \qquad y_{iF} = \frac{F_i^{(2)}}{N_i}. \tag{2}$$

O denominador continua sendo o eleitorado apto do primeiro turno. O percentual entre votos válidos será calculado depois, ao agregar as contagens previstas.

A especificação relaciona essas respostas às cinco proporções:

$$\boxed{y_{id} = \sum_{g \in \mathcal{G}} x_{ig}\beta_{gd} + \varepsilon_{id}, \qquad d \in \{L, F\}.} \tag{3}$$

Nas equações observadas, o índice d identifica Lula ou Flávio. Na simulação com zero urnas, também considero branco/nulo e ausência. β_{gd} é o coeficiente associado à origem g na equação desse destino, e ε_{id} representa o desvio em relação à relação especificada. Para Lula, a equação aberta é:

$$\begin{aligned} y_{iL} = x_{iL}\beta_{LL} + x_{iF}\beta_{FL} + x_{iO}\beta_{OL} \\ + x_{iBN}\beta_{BNL} + x_{iA}\beta_{AL} + \varepsilon_{iL}. \end{aligned} \tag{4}$$

À esquerda está a votação observada de Lula como fração dos aptos. À direita, eu combino o perfil do primeiro turno com cinco coeficientes. Ao estimá-los, eu procuro uma relação que se ajuste às diferenças de votação entre as seções observadas. Depois do ajuste, o resíduo é a diferença entre a resposta observada e a ajustada: $\hat{\varepsilon}_{id} = y_{id} - \hat{y}_{id}$.

Escrever um termo de erro não estabelece que os desvios sejam independentes, normais ou tenham a mesma variância. Essas propriedades não decorrem da equação, e a organização geográfica das seções importa para a estimação e a extrapolação.

2. Por que impus restrições aos coeficientes

Na simulação com zero urnas, a matriz completa β tem cinco origens e quatro destinos: Lula, Flávio, branco/nulo e ausência. Por exemplo, β_{OL} liga Outros a Lula, e β_{AA} liga Ausências a ausência. Depois dos primeiros votos, estimo apenas as colunas de Lula e Flávio, obtendo uma matriz 5×2. O restante reúne branco/nulo e ausência.

Para cada origem g, os sorteios da etapa sem urnas respeitam:

$$\beta_{gd} > 0, \qquad \beta_{gL} + \beta_{gF} + \beta_{gBN} + \beta_{gA} = 1. \tag{5}$$

Assim, a contribuição de cada grupo é repartida entre quatro destinos que esgotam o total.

A previsão em proporções é $\hat{y}_{id} = \sum_g x_{ig}\beta_{gd}$. Para obter uma contagem, eu multiplico pelos aptos:

$$\widehat{V}_{id}^{(2)} = N_i \sum_{g \in \mathcal{G}} x_{ig}\beta_{gd}. \tag{6}$$

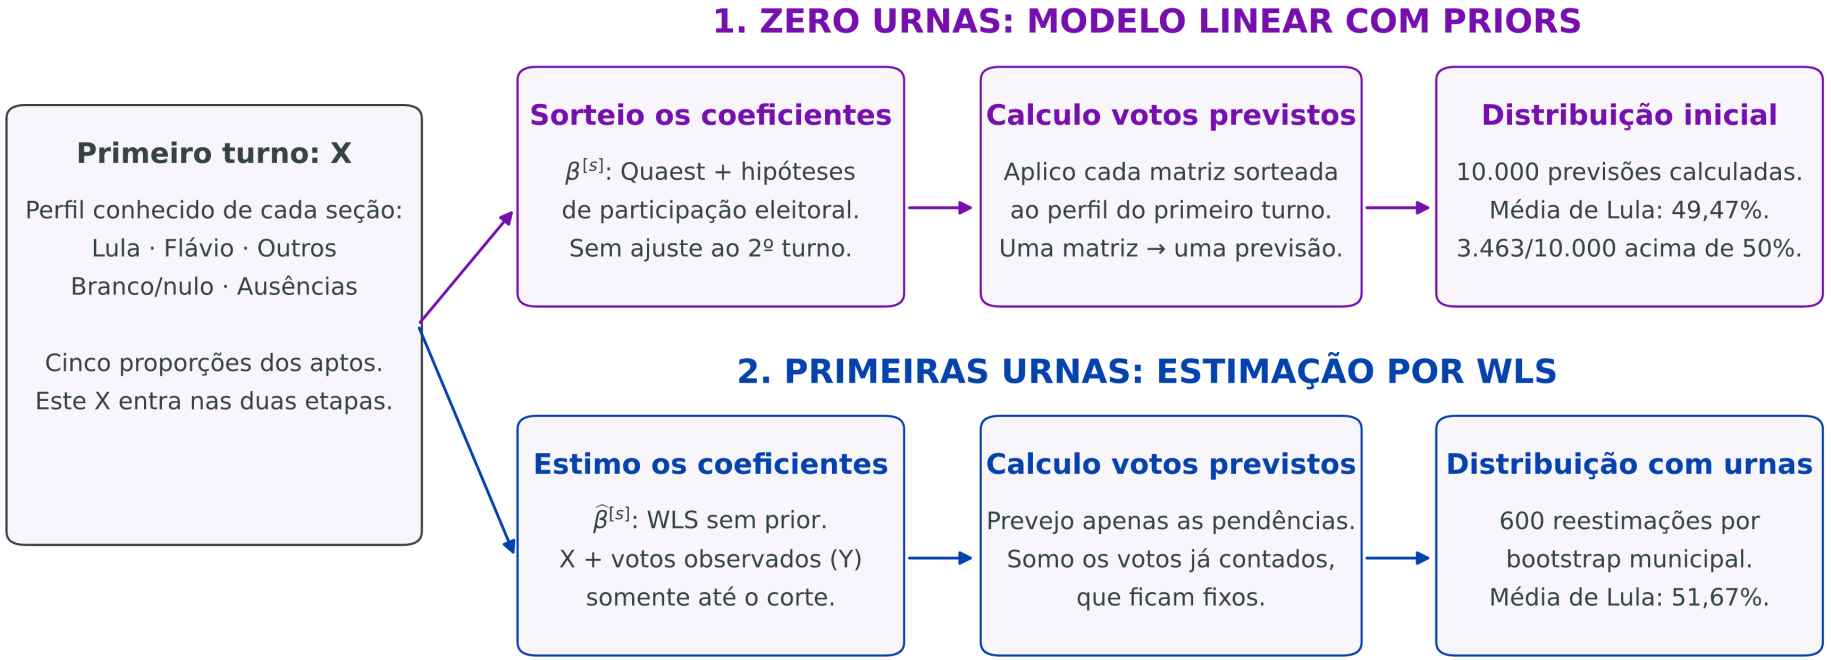
Na previsão a priori, as restrições garantem que as quatro contagens previstas somem N_i. Uso, portanto, um **modelo linear com priors e restrições de composição**. A relação é linear nos coeficientes; o percentual nacional nos válidos é calculado depois, como razão entre totais previstos. Com respostas do segundo turno, estimo a parte de Lula e Flávio por WLS. A mesma conta de projeção recebe coeficientes sorteados ou estimados, conforme a etapa.

Mantive as cinco origens e não acrescentei intercepto. Como as proporções somam um, uma constante adicional seria combinação exata dessas explicativas e deixaria a especificação redundante.

Os quatro destinos pertencem à simulação com priors, antes da apuração. Na estimação com urnas, **apenas Lula e Flávio entram como respostas observadas**. Estimo β_{gL} e β_{gF}, ambos não negativos, com $\beta_{gL} + \beta_{gF} \leq 1$. O restante, $1 - \beta_{gL} - \beta_{gF}$, não identifica separadamente branco/nulo e ausência.

Um modelo linear, duas formas de obter os coeficientes

Antes: priors aplicados ao primeiro turno. Depois: coeficientes ajustados aos votos do corte.



A conta de projeção é linear nas duas etapas: $\widehat{V}_{id} = N_i \sum_g x_{ig} \beta_{gd}$. Muda a origem de β.

GUIA DE LEITURA DOS SÍMBOLOS E NÚMEROS

Os dados do primeiro turno

i = seção; N_i = seus eleitores aptos.
g = um dos cinco grupos de origem.
x_{ig} = parcela dos aptos da origem g.
X reúne essas parcelas em todas as seções.
Y são votos do segundo turno por apto.

Prever com um modelo linear

d = destino; β_{gd} liga origem a destino.
Zero urnas: sorteio β, depois calculo votos.
Não sorteio o percentual final diretamente.
s identifica a simulação ou reestimação.
$\widehat{V}_{id}$ = contagem prevista no destino.

Estimar um coeficiente

$\widehat{\beta}$ é obtido com X e Y observados.
WLS = mínimos quadrados ponderados.
10.000 = previsões a priori do modelo.
600 = regressões com bootstrap municipal.
Mesma fórmula; fontes distintas para β.

Figura 1. Antes da apuração, aplico coeficientes sorteados ao primeiro turno para obter a distribuição inicial. Com os primeiros votos, estimo novos coeficientes por WLS sem prior e prevejo as pendências. O modelo linear já está presente antes das urnas; a estimação aos votos observados começa depois.

Em notação matricial, as equações observadas são $Y = X\beta_{LF} + E$: X tem cinco colunas, Y e E têm duas, e a matriz estimada β_{LF} tem dimensão 5×2. A matriz 5×4 é usada apenas na simulação com zero urnas.

Não incluí efeitos fixos de UF, município ou seção. O primeiro turno fornece as explicativas X; com urnas, a apuração fornece as respostas Y. A Quaest informa somente os cenários da etapa sem urnas. A reamostragem por município mantém suas seções juntas e não acrescenta efeitos fixos.

Os coeficientes são globais: seções com composições diferentes recebem previsões diferentes, mas usam a mesma β. Repare que eles descrevem relações agregadas entre seções. O sigilo do voto e a observação de totais por seção impedem interpretar automaticamente esses coeficientes como taxas comprovadas de mudança de voto de cada pessoa.

Na interpretação das explicativas, aumentar uma proporção exige reduzir outra. Se a participação da origem g aumenta em δ e a da origem h diminui na mesma quantidade, mantendo os coeficientes fixos, a mudança prevista é:

$$\Delta\hat{y}_{id} = \delta(\beta_{gd} - \beta_{hd}). \tag{7}$$

Essa é uma comparação entre composições dentro do modelo, sem interpretação causal automática.

3. Como a equação vira uma previsão de votos

Vou usar uma seção fictícia com 1.000 aptos: 400 votos em Lula, 350 em Flávio, 100 em outros candidatos, 50 brancos/nulos e 100 ausências no primeiro turno. Suponha, só para ilustrar, que os coeficientes para o destino Lula sejam 0,90; 0,02; 0,40; 0,20; e 0,20.

Como $N_i x_{ig}$ é a contagem do grupo g, a equação de previsão pode ser calculada diretamente com essas contagens:

$$\begin{aligned}\widehat{L}_i^{(2)} &= 400 \times 0{,}90 + 350 \times 0{,}02 + 100 \times 0{,}40 \\ &\quad + 50 \times 0{,}20 + 100 \times 0{,}20 \\ &= 437.\end{aligned} \tag{8}$$

A parcela de Outros, por exemplo, acrescenta $100 \times 0{,}40 = 40$ votos à previsão. Se a mesma conta para Flávio produzir 398 votos, Lula terá 43,7% dos aptos previstos para seu destino, mas seu percentual entre os válidos será:

$$100\frac{437}{437 + 398} = 52{,}34\%. \tag{9}$$

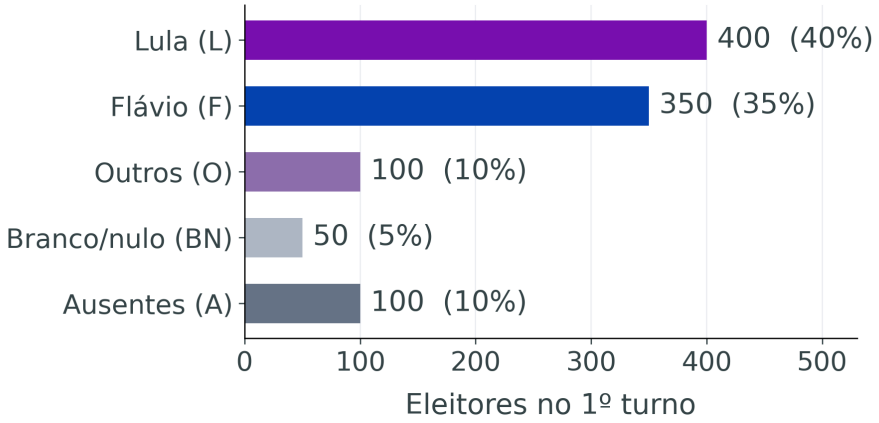
Essa distinção entre denominadores acompanha todo o exercício: **a regressão trabalha em frações dos aptos; o placar usa a participação nos votos válidos**. Para obter o placar nacional, eu somo as contagens de todas as seções antes de calcular o percentual. Uma média simples dos percentuais das seções daria o mesmo peso a eleitorados de tamanhos diferentes.

Aplicar coeficientes: do perfil da seção aos votos previstos

Exemplo fictício: os coeficientes abaixo são hipóteses didáticas, não estimativas de uma regressão.

Perfil da seção no 1º turno

1.000 aptos; os percentuais usam esse total



Contribuições à previsão de Lula

Origem g	$\beta_{g,L}$	Contagem × coeficiente
L	0,90	400 × 0,90 = 360
F	0,02	350 × 0,02 = 7
O	0,40	100 × 0,40 = 40
BN	0,20	50 × 0,20 = 10
A	0,20	100 × 0,20 = 20

Previsão para Lula: 360 + 7 + 40 + 10 + 20 = 437 votos

Para comparar os dois denominadores, suponha também 398 votos previstos para Flávio.

Percentual dos aptos

$$100 \times 437/1.000 = 43{,}70\%$$

Percentual dos votos válidos

$$100 \times 437/(437 + 398) = 52{,}34\%$$

COMO LER CADA LETRA, COEFICIENTE E DENOMINADOR

Grupos e contagens

g = grupo do 1º turno (origem).
L = Lula; F = Flávio.
O = outros candidatos.
BN = branco/nulo; A = ausência.
1.000 = eleitorado apto da seção.
% das barras = contagem / 1.000 × 100.

Coeficientes e parcelas

$\beta_{g,L}$ = coeficiente que multiplica a contagem de g para prever Lula.
0,90 = 90%; 0,02 = 2%; 0,40 = 40%.
0,20 = 20%.
Contagem × coeficiente = parcela.
Somar as cinco parcelas produz 437.

Dois denominadores

437 = previsão de Lula, não observado.
398 = hipótese adicional para Flávio.
835 = 437 + 398 válidos previstos.
1.000 inclui válidos, BN e ausentes.
Multiplicar por 100 converte em %.
52,34% é a parcela de Lula nos 835 válidos.

Figura 2. Exemplo fictício de aplicação da fórmula. Os coeficientes são hipóteses didáticas, não estimativas. Multiplico-os pelas contagens do primeiro turno e depois calculo o percentual nos válidos.

4. Como usei um prior antes da primeira urna

Com zero urnas, faço previsão a priori de um modelo linear. Conheço X, o perfil do primeiro turno, e obtenho $\beta^{[s]}$ dos priors. Ainda não observo Y, os votos do segundo turno, para ajustar esses coeficientes. Posso, mesmo assim, aplicar o modelo e calcular médias, quantis e a parcela dos cenários acima de 50%. Não há uma estimação por mínimos quadrados escondida nessa etapa.

O **prior** representa minha incerteza sobre esses valores antes de observar as novas respostas. Vale comparar com a interpretação frequentista usual, em que os parâmetros são tratados como fixos e se estuda como seus estimadores variariam entre amostras. O prior, por sua vez, é uma distribuição sobre os próprios valores dos parâmetros, construída a partir da informação e das hipóteses disponíveis.

Aqui, a pesquisa e as hipóteses de participação geram uma distribuição de matrizes $\boldsymbol{\beta}$. Cada matriz sorteada produz uma previsão para todas as seções, e repetindo a operação obtenho uma distribuição de resultados nacionais. Dentro de cada cenário, aplico a mesma matriz ao conjunto das seções; não sorteio coeficientes independentes para cada lugar.

Para mostrar como essa transformação funciona, vou usar um exemplo simplificado, separado do anterior. Considere novamente 1.000 aptos. Suponha que quatro origens, com suas contribuições fixadas, produzam 400 votos para Lula, 370 para Flávio, 50 brancos/nulos e 80 ausências. São 900 pessoas distribuídas entre os destinos.

Restam 100 eleitores de Outros. Para simplificar, todos produzem votos válidos e apenas um coeficiente é incerto: β, abreviação de β_{OL} neste exemplo, a fração prevista desse grupo para Lula. A fração para Flávio é $1-\beta$. Logo:

$$L(\beta) = 400 + 100\beta, \qquad F(\beta) = 470 - 100\beta. \tag{10}$$

Há sempre 870 votos válidos. O percentual previsto de Lula, θ, depende de β:

$$\theta(\beta) = 100\frac{400 + 100\beta}{870}. \tag{11}$$

Suponha um prior uniforme entre 0,30 e 0,50. Isso significa atribuir o mesmo peso a intervalos de igual comprimento dentro dessa faixa. Alguns valores ilustram a transformação:

β	Votos de Lula	Votos de Flávio	Lula nos válidos
0,30	430	440	49,43%
0,35	435	435	50,00%
0,40	440	430	50,57%
0,50	450	420	51,72%

Lula supera 50% quando recebe mais de 435 votos, o que exige $\beta > 0{,}35$. A probabilidade vem da parcela do prior que satisfaz essa condição:

$$P(\theta > 50) = P(\beta > 0{,}35) = \frac{0{,}50 - 0{,}35}{0{,}50 - 0{,}30} = 75\%. \tag{12}$$

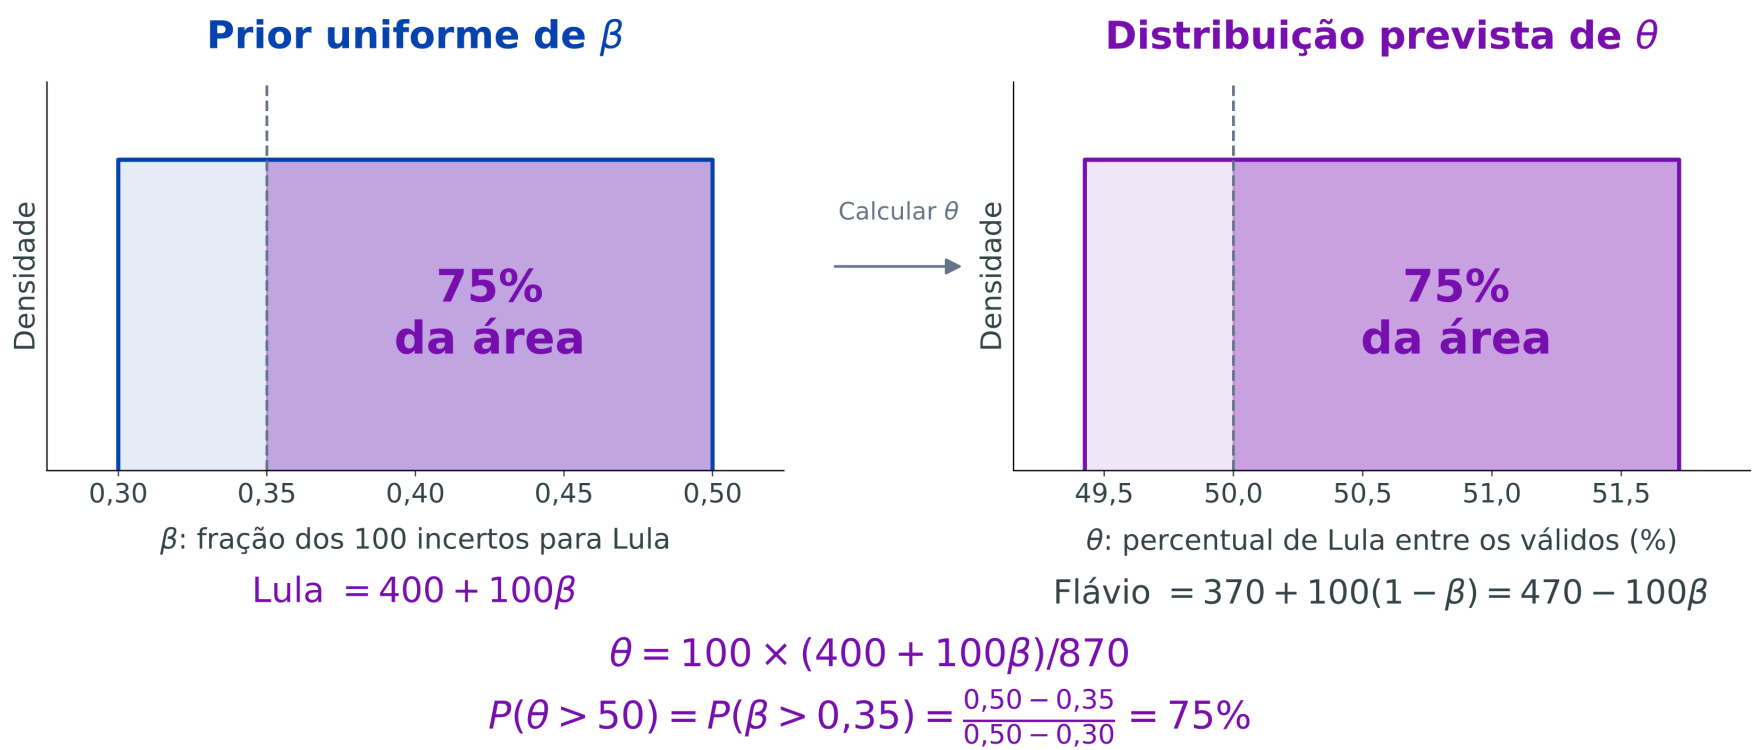


Figura 3. Exemplo fictício com zero urnas: sorteio um coeficiente e aplico a fórmula a cada valor para obter uma distribuição da votação. A área acima de 50% é 75% neste exemplo, e não corresponde ao resultado do exercício Quaest.

As linhas da tabela são pontos ilustrativos, não quatro sorteios com pesos iguais. A conta usa a área da distribuição. Nesse exemplo, a transformação gera uma distribuição uniforme de θ entre 49,43% e 51,72%. Se sorteássemos 10.000 valores de β, esperaríamos aproximadamente 7.500 resultados acima de 50%.

Mudar o prior altera a conclusão: com β uniforme entre 0,20 e 0,40, a parcela acima de 0,35 seria de 25%. A equação traduz coeficientes em votos; o prior atribui peso aos valores possíveis dos coeficientes.

Esse uso de priors para prever antes de observar a resposta é compatível com a formulação bayesiana de modelos de regressão. A documentação do Stan apresenta a previsão a priori com explicativas conhecidas. No meu código, propago a incerteza dos coeficientes e da participação até os totais projetados; não acrescento nessa etapa um sorteio separado do erro eleitoral. Assim, a distribuição descreve as projeções sob essas hipóteses, sem garantir que toda a incerteza sobre o resultado real esteja representada.

Essa construção também distingue duas medidas: a **votação média prevista** resume os percentuais gerados; a **frequência de cenários acima de 50%** mede a parcela da distribuição que satisfaz o critério de maioria dos válidos no universo projetado.

5. Como a Quaest virou o prior dos coeficientes

Quero abrir essa parte com os números reais, porque dizer apenas que usei a Quaest como prior esconde várias decisões. A pesquisa informa intenções declaradas de voto. Eu escolhi como representar a incerteza dessas intenções, como tratar quem havia faltado ou votado branco/nulo e como compatibilizar a conta com a participação eleitoral. Os 34,63% são o resultado dessa construção.

Com zero urnas, conheço as explicativas X do primeiro turno. Elas entram no modelo, mas sozinhas não identificam os coeficientes que ligam os dois turnos. A informação da Quaest e minhas hipóteses de participação fornecem os priors para esses coeficientes. **Os 34,63% vêm da previsão a priori do modelo linear, sem ajuste a votos observados do segundo turno.** Com as primeiras urnas, passo a estimar os coeficientes com os resultados do corte. São duas formas de obter os coeficientes da estrutura linear; não existe uma terceira previsão com zero urnas descartada.

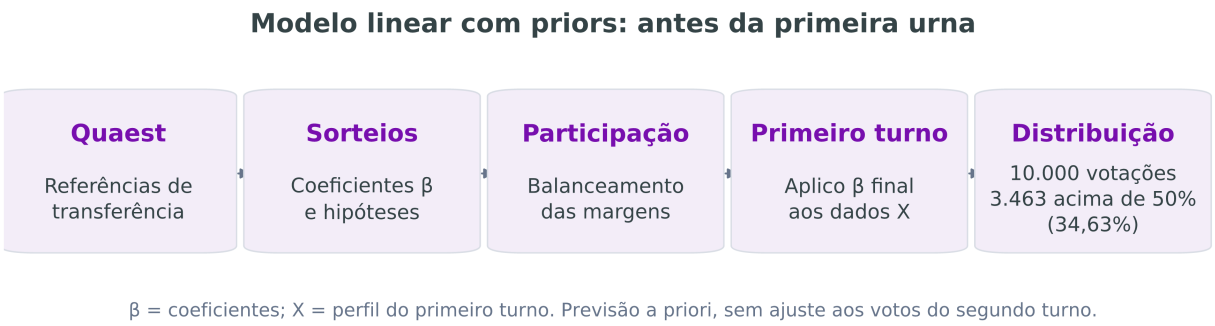


Figura 4. A pesquisa e as hipóteses de participação geram coeficientes sorteados e balanceados. Aplico esses coeficientes ao primeiro turno para calcular cada votação. A distribuição inicial é a previsão a priori do modelo linear, sem ajuste por WLS a votos do segundo turno.

5.1 O que veio da pesquisa

Usei a tabela de transferência da Genial/Quaest de 21 de outubro de 2026, página 19. Ela relaciona o voto declarado no primeiro turno à intenção no segundo:

Origem declarada no primeiro turno	Lula	Flávio	Restante
Lula	95%	0%	5%
Flávio	0%	94%	6%
Outros candidatos	37%	43%	20%
Branco/nulo ou não compareceu	40%	36%	24%

O restante reúne indecisos e intenções de branco/nulo/não comparecimento. A pesquisa também junta, numa mesma origem, quem votou branco/nulo e quem não compareceu. Minha estrutura de origens distingue esses grupos. Precisei acrescentar hipóteses para fazer essa passagem; intenção declarada e voto efetivamente realizado são quantidades diferentes.

5.2 Como escolhi a distribuição

Cada origem precisa distribuir sua contribuição entre quatro destinos: Lula, Flávio, branco/nulo e ausência. Escolhi uma **Dirichlet** porque ela sorteia proporções positivas que somam 1. Assim, os coeficientes já nascem respeitando a contabilidade do modelo.

Primeiro, dividi o restante entre branco/nulo e ausência. Para cada linha, sorteei uma fração r de uma uniforme entre zero e um. Na linha Outros, as referências ficam:

$$r \sim \text{Uniforme}(0,1), \qquad p_L = 0{,}37, \quad p_F = 0{,}43, \quad p_{BN} = 0{,}20r, \quad p_A = 0{,}20(1-r). \tag{13}$$

Aqui, p_d é a referência do destino d naquela linha, e r é a fração do restante atribuída a branco/nulo. A divisão uniforme é uma escolha minha: a pesquisa não determina essa repartição.

Com essas referências, sorteei o vetor inicial de coeficientes:

$$\boldsymbol{\beta}_g^{\text{inicial}} \mid r \sim \text{Dirichlet}(\alpha_{gL}, \alpha_{gF}, \alpha_{gBN}, \alpha_{gA}), \qquad \alpha_{gd} = 0{,}5 + 100p_{gd}. \tag{14}$$

O índice g identifica a origem, d o destino e α os parâmetros que controlam a distribuição. **O 100 foi uma escolha de concentração, não o tamanho da amostra da Quaest nem uma base efetiva demonstrada dos subgrupos.** Valores maiores dão mais peso às referências e concentram mais os sorteios.

Acrescentei 0,5 a cada destino para manter suporte positivo inclusive onde a pesquisa publicou 0%. Essa suavização permite os ajustes posteriores de participação, mas também altera ligeiramente as médias. Como as quatro referências somam 1, a soma dos parâmetros é $100 + 4(0{,}5) = 102$.

Para Outros, por exemplo:

$$\boldsymbol{\beta}_O^{\text{inicial}} \mid r \sim \text{Dirichlet}\left(37{,}5;\ 43{,}5;\ 0{,}5 + 20r;\ 0{,}5 + 20(1-r)\right). \tag{15}$$

A média inicial do coeficiente para Lula é $37{,}5/102 = 0{,}367647$, ou 36,76%, com desvio padrão de aproximadamente 4,75 pontos percentuais. Esses números ainda são anteriores aos fatores de realização e à calibração de participação.

5.3 Um sorteio real dessa distribuição

No primeiro cenário calculado, a fração residual da linha Outros foi $r = 0{,}139670$. Os parâmetros usados foram:

$$\boldsymbol{\alpha}_O = (37{,}5;\ 43{,}5;\ 3{,}293400;\ 17{,}706600). \tag{16}$$

O sorteio produziu os seguintes coeficientes iniciais:

Destino	Coeficiente sorteado
Lula	0,310207
Flávio	0,493341
Branco/nulo	0,043284
Ausência	0,153168

Esses são valores de uma execução real, arredondados na tabela. Os 37% da Quaest informam a distribuição; um sorteio particular pode produzir 31,02%. A frequência final depende do conjunto dos sorteios, não de fazer cada um repetir o percentual publicado.

5.4 Como tratei quem faltou ou votou branco/nulo

Copiei o mesmo sorteio da linha mista da Quaest para as duas origens, branco/nulo e ausência. Depois introduzi dois fatores independentes, q_{BN} e q_A, ambos uniformes entre zero e um, para representar a realização do apoio declarado:

$$q_{BN}, q_A \sim \text{Uniforme}(0,1), \qquad \beta_{gL} \leftarrow q_g \beta_{gL}, \quad \beta_{gF} \leftarrow q_g \beta_{gF}, \quad g \in \{BN, A\}. \tag{17}$$

O fator q_g multiplica a parte destinada aos votos válidos. A massa retirada volta para branco/nulo na origem BN e para ausência na origem A, preservando a soma 1. No primeiro cenário, $q_A = 0{,}319423$ e $q_{BN} = 0{,}823318$.

Esses fatores são hipóteses do exercício. A uniforme tem média 0,5, mas isso não demonstra que metade do apoio declarado será realizado. Ela atribui o mesmo peso a intervalos de igual comprimento na taxa de realização. A taxa de comparecimento de cada pessoa não foi identificada.

5.5 A participação que usei antes da apuração

Para calibrar os totais de participação, usei as mudanças entre os dois turnos de 2014, 2018 e 2022. O comparecimento é medido como proporção dos aptos do primeiro turno. A taxa de branco/nulo usa os presentes como denominador:

Ano	Mudança no comparecimento, em p.p. dos aptos	Mudança no logit da taxa de BN
2014	-1,712221	-0,455560
2018	-0,973805	0,093384
2022	0,362296	0,041382

Há apenas três eleições independentes nesse cálculo. Modelei cada mudança por uma normal com média e variância desconhecidas e prior de referência proporcional a $1/\sigma^2$, onde σ^2 é a variância. A distribuição preditiva resultante é uma Student-t com dois graus de liberdade:

$$\begin{aligned} \Delta C &= -0{,}774576 + 1{,}214180\, t_C, \\ \Delta b &= -0{,}106931 + 0{,}349919\, t_b, \qquad t_C, t_b \overset{\text{ind}}{\sim} t_2. \end{aligned} \tag{18}$$

ΔC é a mudança do comparecimento em pontos percentuais dos aptos; Δb é a mudança na escala logit da taxa de branco/nulo. t_C e t_b são sorteios independentes de uma Student-t padronizada com dois graus de liberdade. Essa escolha produz caudas pesadas: a variância bruta dessa Student-t não é finita. A restrição física do comparecimento é aplicada depois, e uso quantis para descrever a incerteza.

Na base doméstica do primeiro turno de 2026, havia 157.828.968 aptos, 124.934.069 presentes e 5.959.040 votos brancos/nulos. Chamo esses totais de N, C_1 e BN_1. Em cada cenário:

$$\begin{aligned} C_2 &= C_1 + N\,\Delta C/100, \\ BN_2 &= C_2\ \text{logit}^{-1}\left[\text{logit}(BN_1/C_1) + \Delta b\right], \\ V_2 &= C_2 - BN_2, \qquad A_2 = N - C_2. \end{aligned} \tag{19}$$

C_2, BN_2, V_2 e A_2 são os totais previstos de comparecimento, branco/nulo, válidos e ausências. Para uma taxa z, $\text{logit}(z) = \log[z/(1-z)]$; sua inversa reconverte o resultado para uma taxa entre zero e um. Condicionei o comparecimento a $0 \le C_2 \le N$, por rejeição de sorteios fora desses limites, sem truncá-los em massas nos extremos.

Gerei 100.000 cenários de participação e selecionei 10.000 sem reposição, com semente fixa, para combinar com os sorteios dos coeficientes. Não usei o resultado do segundo turno de 2026 para estimar essas distribuições.

5.6 Como o balanceamento altera os coeficientes

As matrizes sorteadas ainda precisam ser compatíveis com os totais de participação de cada cenário. Fiz isso por IPF, um balanceamento iterativo que conserva o tamanho de cada origem e ajusta três totais nacionais: válidos, branco/nulo e ausência.

Não forneci um total desejado de Lula ou Flávio ao balanceamento. Dentro de cada origem e cenário, preservei a proporção Lula/Flávio entre os votos válidos. O ajuste muda quanto cada origem contribui para os válidos, e essa mudança pode alterar o placar nacional porque as origens têm diferentes preferências.

A construção original tem 15 origens. Os 11 candidatos eliminados compartilham a referência de 37%/43% e o mesmo sorteio inicial. Agreguei suas linhas com pesos nacionais para formar Outros, preservando os totais nacionais de cada cenário. As cinco origens finais são as que entram na regressão.

As médias dos 10.000 conjuntos de coeficientes, depois de todas essas transformações, foram:

Origem	Para Lula	Para Flávio	Para BN	Para ausência
Lula	0,9061	0,0049	0,0227	0,0663
Flávio	0,0046	0,8938	0,0258	0,0757
Outros	0,3356	0,3876	0,0657	0,2111
Branco/nulo	0,2132	0,1920	0,3105	0,2843
Ausentes	0,1343	0,1211	0,0515	0,6932

Cada linha soma 1 antes do arredondamento. Essa tabela resume o prior final usado na previsão: a distribuição já foi transformada pelos fatores de realização e pela calibração histórica. Ela não é uma transcrição da Quaest nem continua sendo simplesmente a Dirichlet inicial. Os coeficientes também não identificam transferências individuais.

5.7 A conta que gerou os 34,63%

Em cada cenário s, apliquei os coeficientes às origens do primeiro turno e somei os votos previstos. Para o destino d, o total $T_d^{[s]}$ e o percentual de Lula $\theta^{[s]}$ são:

$$T_d^{[s]} = \sum_i N_i \sum_g x_{ig} \beta_{gd}^{[s]}, \qquad \theta^{[s]} = 100 \frac{T_L^{[s]}}{T_L^{[s]} + T_F^{[s]}}. \tag{20}$$

Vou abrir o primeiro cenário. Multipliquei as cinco contagens de origem pelos respectivos coeficientes finais para Lula:

$$\begin{aligned} \widehat{V}_L^{[1]} &\simeq 53.722.151(0{,}8224868) \\ &\quad + 55.960.603(0{,}0007169) \\ &\quad + 9.292.275(0{,}1896237) \\ &\quad + 5.959.040(0{,}2386954) \\ &\quad + 32.894.899(0{,}0354931) \\ &\simeq 48.577.851. \end{aligned} \tag{21}$$

A mesma conta para Flávio produziu aproximadamente 51.638.270 votos. Dividindo Lula pela soma dos dois, obtive 48,4731% dos válidos naquele cenário. São contagens esperadas contínuas, arredondadas aqui para facilitar a leitura; não são urnas artificiais sorteadas eleitor por eleitor.

Os três primeiros cenários, sem escolher os mais favoráveis, foram:

Cenário	Votos previstos de Lula	Votos previstos de Flávio	Lula nos válidos
1	48.577.851	51.638.270	48,4731%
2	59.213.819	58.152.536	50,4521%
3	54.314.326	60.604.938	47,2630%

Repeti a conta nos 10.000 cenários. Em 3.463 deles, Lula passou de 50%:

$$\frac{\#\{s : \theta^{[s]} > 50\}}{10.000} = \frac{3.463}{10.000} = 34{,}63\%. \tag{22}$$

O símbolo # conta quantos cenários satisfazem a condição. A média dos percentuais foi 49,4712%. A frequência de 34,63% exige os sorteios conjuntos: calcular uma única votação com os coeficientes médios não recupera essa frequência. A razão entre as contagens médias também é outra estatística; neste caso, ela dá 49,4581%.

5.8 Quanto a escolha da distribuição pesa no resultado

Nos testes de concentração já calculados, mantendo o restante da construção, encontrei:

Concentração escolhida	Média de Lula nos válidos	Cenários acima de 50%
25	49,45%	41,26%
100	49,47%	34,63%
400	49,46%	29,04%

Os testes usam sementes diferentes, sem emparelhamento dos números aleatórios. Eles mostram a sensibilidade à concentração adotada. O centro ficou parecido, mas a frequência acima de 50% mudou com a dispersão e a suavização.

Por isso, descrevo os 34,63% como **frequência de cenários condicional às hipóteses do modelo**. A concentração 100, o acréscimo de 0,5, os fatores uniformes e a participação histórica fazem parte dessas hipóteses. O número não é uma probabilidade publicada pela Quaest nem uma frequência de acerto já validada em várias eleições.

Reproduzi os 100.000 sorteios de participação e os 10.000 cenários finais numa auditoria. Os coeficientes finais foram recuperados exatamente, e a contagem voltou a ser 3.463. Essa reprodução confirma a implementação da conta; a escolha da especificação continuou sendo retrospectiva.

6. Como estimei a regressão com os primeiros votos

O corte principal, também usado na comunidade e no carrossel, reúne 4.984 de 499.206 seções nacionais: 0,9984%, às 19h04min21s de 25/10/2026 no horário registrado pelo TSE. O ajuste usa 4.208 seções domésticas de 330 municípios, equivalentes a 0,8452% das seções no Brasil sem exterior. A aplicação do estimador e as figuras principais abaixo usam esse corte; os resultados de cerca de 2% são uma análise complementar.

Na análise complementar de 2%, fixei o último lote completo até aproximadamente 2% das seções nacionais: 9.981 de 499.206, às 19h16min39s de 25/10/2026 no horário registrado pelo TSE. Dessas,

9.205 pertencem ao universo doméstico projetado, distribuídas por 905 municípios. Elas representam 1,8488% das 497.897 seções domésticas; restam 488.692 para prever. O corte nacional inclui o exterior; o universo projetado considera apenas as seções no Brasil.

Chamo de $\mathcal{O}$ o conjunto de seções observadas (diferente da origem Outros, indicada por O). Agora tenho as explicativas X e as respostas Y nessas seções. Estimo os coeficientes que melhor relacionam o perfil do primeiro turno aos votos disponíveis no corte. **Nesta etapa, não uso Quaest, priors, penalização nem calibração histórica de participação.**

O estimador por mínimos quadrados ponderados, ou WLS, é:

$$\begin{aligned} \widehat{\boldsymbol{\beta}}_{LF} = \arg\min_{\boldsymbol{\beta}_{LF}} \quad & \frac{1}{2}\sum_{i\in\mathcal{O}} w_i \sum_{d\in\{L,F\}} \left(y_{id} - \sum_{g} x_{ig}\beta_{gd} \right)^2, \\ \text{sujeito a} \quad & \beta_{gL} \geq 0, \quad \beta_{gF} \geq 0, \quad \beta_{gL} + \beta_{gF} \leq 1. \end{aligned} \tag{23}$$

Aqui, $w_i = N_i/\overline{N}_{\mathcal{O}}$, e $\overline{N}_{\mathcal{O}}$ é a média dos eleitorados das seções observadas. A notação arg min indica a matriz que minimiza a soma ponderada dos erros quadráticos. O peso faz um desvio da mesma magnitude, medido em fração dos aptos, pesar mais numa seção maior. É um peso populacional; não estimei uma variância específica para cada seção.

São cinco explicativas e duas respostas. A matriz estimada tem dimensão 5×2. Os coeficientes podem ser zero, e a soma das contribuições de Lula e Flávio em cada origem não pode ultrapassar um. Essas restrições evitam previsões negativas e impedem que os dois candidatos recebam, juntos, mais votos que o eleitorado considerado. O restante reúne branco/nulo e ausência, sem estimar sua divisão.

Não há parâmetro de penalização nem seleção de sua intensidade. O ajuste pontual parte de uma constante neutra no otimizador e resolve um problema quadrático convexo com restrições. Os ajustes de bootstrap usam esse ponto estimado como início computacional; nenhum deles recebe coeficientes da Quaest. O código verifica as condições de ótimo e a viabilidade das soluções.

6.1 Por que deixei o prior apenas na etapa sem urnas

Na primeira versão deste exercício, eu mantinha o prior da Quaest também depois das primeiras urnas, por meio de uma penalização. Testei sua retirada e as médias nacionais ficaram praticamente iguais: com cerca de 1%, de 51,671% para 51,674%; com cerca de 2%, de 51,643% para 51,645%. Nesse teste, os dados observados já dominavam a previsão nacional. Por isso, simplifiquei o procedimento: **mantenho os priors na etapa sem urnas e estimo a regressão sem prior depois dos primeiros votos.** Registro a comparação para deixar claro o que mudou nesta revisão; ela não representa um ganho relevante de acurácia em relação à versão anterior.

As restrições continuam sendo uma escolha da especificação. Uma WLS sem essas restrições produziu previsões incompatíveis com a contabilidade dos aptos em 504 seções pendentes no corte de 1% e 501 no de 2%: votos negativos para um candidato ou soma dos dois acima dos aptos. Isso motivou manter a não negatividade e o limite de soma, sem manter a penalização por pesquisa. Esses testes não demonstram superioridade geral em outras eleições.

7. De onde veio a distribuição de previsões

Para representar a variação do ajuste, fiz **600 reestimações por bootstrap municipal**. Em cada repetição, sorteio municípios com reposição: alguns aparecem mais de uma vez, outros ficam de fora. Cada município sorteado leva todas as suas seções disponíveis no corte, e estimo novamente a mesma WLS restrita, sem prior.

No corte de menos de 1%, sorteio 330 municípios em cada repetição; no corte de cerca de 2%, sorteio 905. A reestimação usa os coeficientes dessa amostra para prever as seções pendentes. Somo essas previsões aos votos já contados, que permanecem fixos. Assim obtenho 600 previsões nacionais, todas usando o mesmo corte de informação. Manter juntas as seções de cada município preserva sua variação conjunta no sorteio, sem acrescentar efeitos fixos.

Os 10.000 cenários iniciais e os 600 reajustes são distribuições de procedimentos diferentes. Antes da apuração, simulo coeficientes e participação a partir de priors. Depois, estimo coeficientes apenas com os votos disponíveis e represento sua variação pelo bootstrap municipal. Não apresento a passagem entre as duas etapas como uma atualização bayesiana de uma única distribuição.

O número 600 é a quantidade de reestimações que calculei nesta execução. Os 600/600 indicam que Lula passou de 50% em todas as previsões geradas. Esse resultado depende do procedimento: os ajustes podem compartilhar os mesmos erros de especificação e de extrapolação. Fazer mais repetições reduziria o ruído numérico da simulação, mas não resolveria esses erros por si só. Não foi demonstrada convergência ao ampliar esse número.

Em cada replicação s, mantenho os votos já contados e projeto apenas as pendências. Para $d \in \{L, F\}$, o total é:

$$T_d^{[s]} = \underbrace{\sum_{i \in \mathcal{O}} V_{id}^{(2)}}_{\text{votos contados}} + \underbrace{\sum_{i \notin \mathcal{O}} N_i \sum_g x_{ig} \hat{\beta}_{gd}^{[s]}}_{\text{votos previstos nas pendências}} . \tag{24}$$

A reamostragem muda os dados usados para estimar β_{LF}; os votos contados permanecem fixos na soma nacional. Nenhuma margem de participação histórica é imposta nesta etapa. Também não sorteio resíduos adicionais para cada seção pendente.

Calculo $\theta^{[s]} = 100 T_L^{[s]} / (T_L^{[s]} + T_F^{[s]})$ em cada replicação e depois obtenho média, quantis e frequência acima de 50%. Com menos de 1%, a média dos bootstraps é 51,6744%, enquanto o ajuste pontual produz 51,6877%. Com cerca de 2%, esses valores são 51,6451% e 51,6288%. São resumos distintos, mesmo quando ficam próximos.

Tudo isso depende de uma hipótese de extrapolação: **a relação entre composição do primeiro turno e votação do segundo, aprendida nas seções que chegaram cedo, precisa ser informativa para as que ainda faltam**. Uso os mesmos coeficientes no país, sem coeficientes específicos por UF.

8. Resultados do procedimento original

Informação disponível	Média de Lula nos válidos	Faixa original: quantis 2,5%–97,5%	Cenários acima de 50%
Zero urnas do segundo turno	49,47%	45,65% a 53,65%	3.463/10.000 - 34,63%
Corte nacional de 1%	51,67%	51,28% a 51,98%	600/600
Corte nacional de 2%	51,65%	51,30% a 51,95%	600/600

A tabela e as distribuições seguintes descrevem o **procedimento original, antes do piso histórico**. Seus quantis e as frequências 600/600 não incluem a correção apresentada na seção de backtest.

As faixas de 95% são os quantis de 2,5% e 97,5% dos bootstraps municipais. No corte de menos de 1%, a média de 51,6744% ficou a aproximadamente 0,105 ponto percentual do resultado doméstico final, de 51,7790%. No corte de cerca de 2%, o erro foi de aproximadamente 0,134 ponto percentual. O resultado final é consultado somente nessa avaliação.

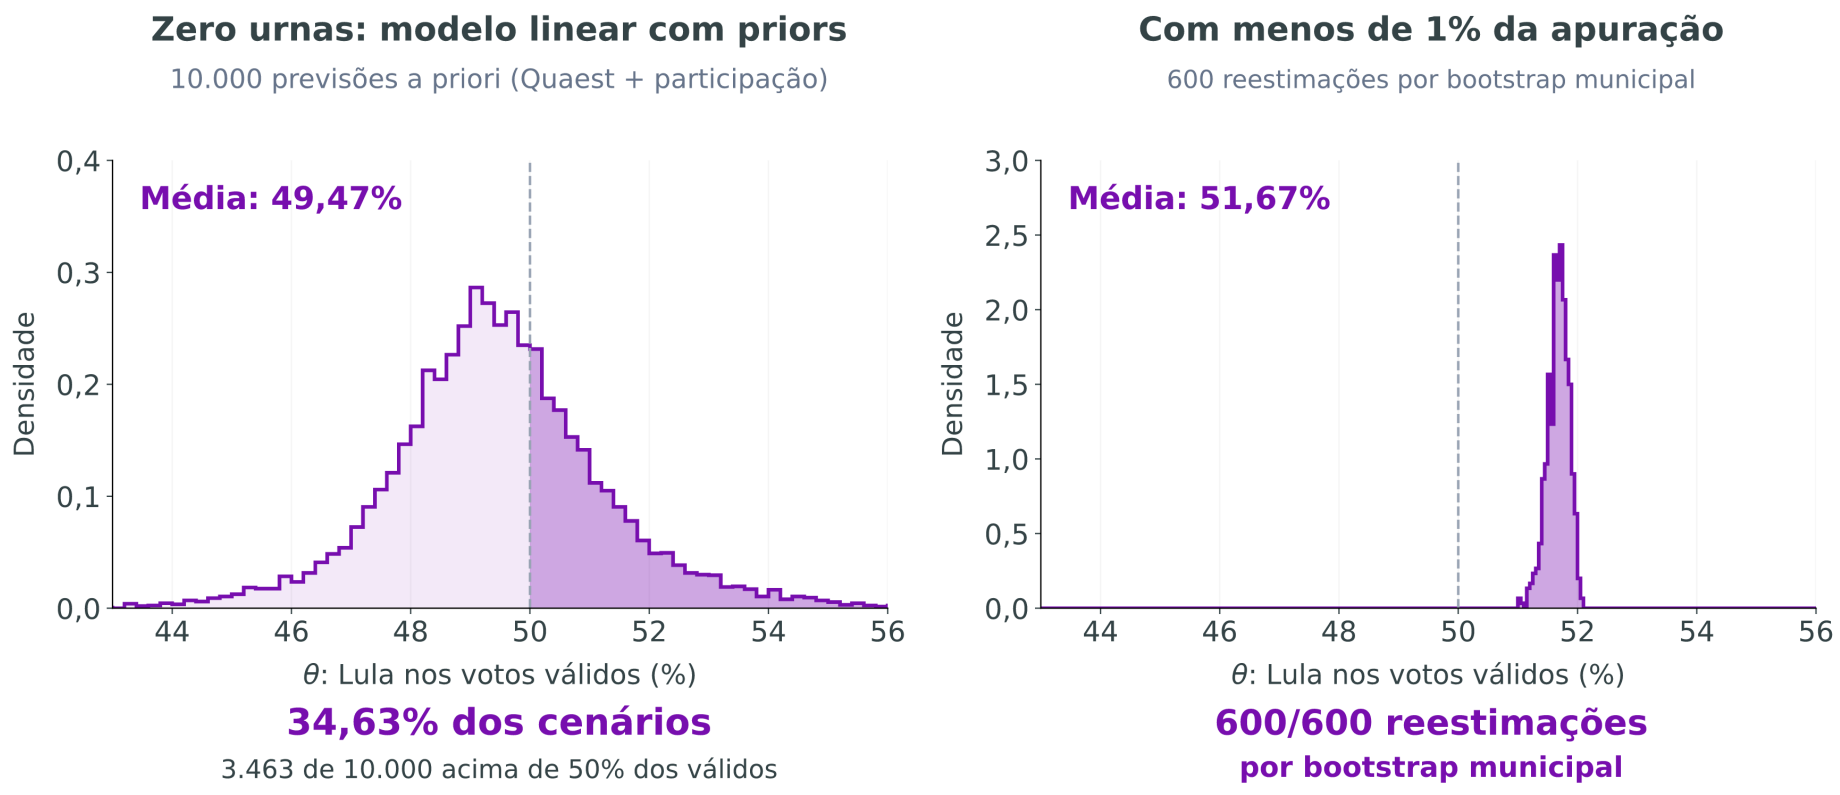


Figura 5. À esquerda, previsão a priori do modelo linear com zero urnas: 3.463 dos 10.000 cenários superam 50%. À direita, regressão estimada com o corte de 0,9984% nacional: 600 reestimações por bootstrap municipal, sem prior, acima de 50%, com média de 51,67% para Lula. São cenários, não urnas.

No corte principal de 0,9984% nacional, Lula tinha 49,28% dos válidos já contados no universo doméstico. Extrapolar essa parcial até o fim daria erro de aproximadamente 2,50 pontos percentuais. A média da regressão, de 51,67%, ficou a cerca de 0,1 ponto percentual dos 51,78% realizados nesse universo, consultados somente na avaliação.

Os 600 cenários acima de 50% mostram o resultado do procedimento sob suas hipóteses. Todos podem compartilhar erros de especificação ou de extrapolação. Se os municípios tardios tiverem comportamentos que não aparecem nos iniciais, reamostrar os municípios observados não reproduzirá automaticamente essa diferença.

Nos gráficos, recortei o eixo entre 43% e 56% dos válidos, o que exclui visualmente 1,06% dos sorteios iniciais. As estatísticas e a normalização das densidades usam todos os sorteios; os dois painéis têm escalas de densidade próprias.

A faixa de 95% cobre a variação representada nos bootstraps municipais. Ela não inclui toda a incerteza sobre a seleção da especificação, os padrões geográficos omitidos ou o processo de chegada dos municípios. As frequências de cenários ainda não foram calibradas como probabilidades de acerto em várias eleições.

9. O que aprendi no backtest histórico

Depois do exercício de 2026, quis verificar a mesma especificação em outros anos. Fixei as regras antes desta rodada e separei os prefixos de ajuste dos arquivos completos de avaliação. Testei 0,5%, 1%, 2%, 5% e 10%, com 600 reestimações municipais por corte.

Em 2014, recuperei os votos, mas não uma cronologia verificável nos arquivos preparados. Em 2018, reconstruí a contagem interna; aqueles cortes ocorreram antes da divulgação pública presidencial, conforme a regra de divulgação daquele ano. Em 2022, os horários são posteriores ao início da divulgação, mas os votos vêm de extratos finais, sem snapshots versionados. O pacote não comprova a disponibilidade pública exata de cada versão histórica.

As faixas bootstrap originais cobriram cinco dos dez cortes calculáveis: três de cinco em 2018 e dois de cinco em 2022. São duas eleições, com cortes dependentes, não dez testes independentes. O bootstrap reamostra municípios que já chegaram e pode deixar de fora diferenças sistemáticas dos lugares pendentes.

9.1 Como calculei o piso histórico

Chamo de j uma eleição histórica, de t o ano-alvo e de c o corte de apuração. θ_j é o resultado agregado observado no ano histórico e $\mu_j(c)$ é o centro do modelo naquele corte. Defino:

$$e_j(c) = \theta_j - \mu_j(c), \qquad r_t(c) = \max_{j<t} |e_j(c)|. \tag{25}$$

Só entram anos anteriores a t, com cronologia elegível e o mesmo corte c. Se $L_t(c)$ e $U_t(c)$ são os extremos bootstrap originais, seus afastamentos do centro são:

$$d_t^-(c) = \mu_t(c) - L_t(c), \qquad d_t^+(c) = U_t(c) - \mu_t(c). \tag{26}$$

Os afastamentos corrigidos ficam:

$$\begin{aligned}\tilde{d}_t^-(c) &= \max\{d_t^-(c), r_t(c)\},\\ \tilde{d}_t^+(c) &= \max\{d_t^+(c), r_t(c)\}.\end{aligned} \tag{27}$$

Em palavras: preservo a faixa original e garanto, em cada direção, pelo menos o maior erro histórico daquele corte. Não interpreto esse máximo como um desvio-padrão ou um quantil de 95% conhecido. Os centros e os coeficientes ficam congelados.

Para avaliar 2022, usei somente os erros de 2018:

Regra	Cortes cobertos	Largura média	Interval score
Original	2 de 5	0,72 p.p.	6,74
Escala histórica	3 de 5	1,18 p.p.	1,29
Piso por corte	5 de 5	2,09 p.p.	2,09

O interval score soma a largura a uma penalidade pela distância de resultados fora da faixa. Com nível nominal de 95%, cada ponto percentual fora dela acrescenta 40 ao score; alargar tudo também tem custo. A escala histórica multiplicou os afastamentos originais por 1,636, aprendido apenas com 2018. Mantive as duas correções como análises distintas, sem escolher novos parâmetros a partir de 2022. A fórmula é de Gneiting e Raftery (2007).

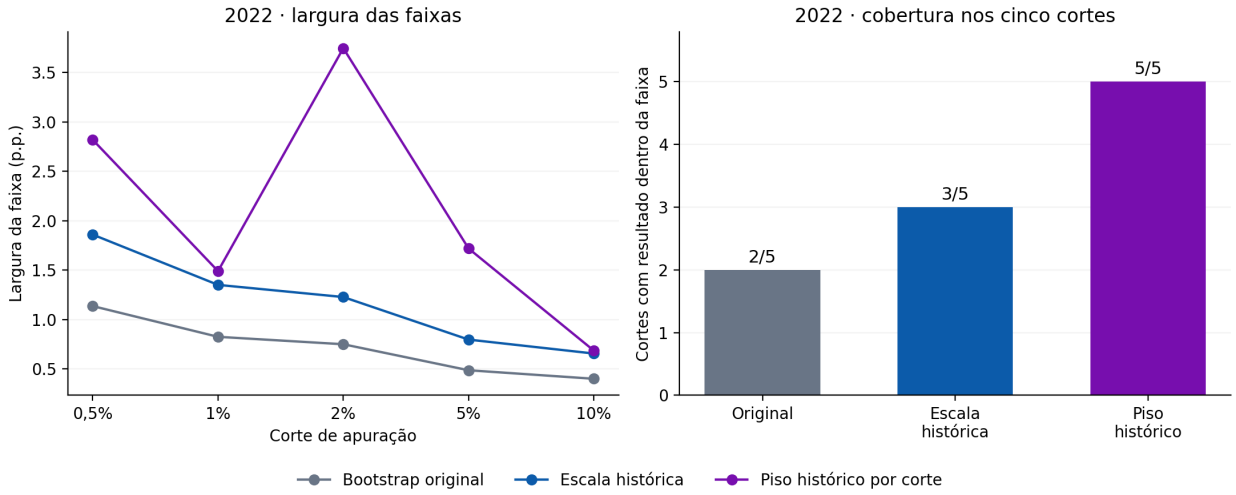


Figura 6. Diagnóstico de largura e cobertura em 2022. As correções usam apenas 2018. Os cinco cortes da mesma eleição são dependentes.

9.2 Aplicação à dispersão dos cortes de 2026

Mantive a regra e usei somente os erros de 2018 e 2022 para calcular os pisos de 2026. A calibração e a aplicação não abriram o desfecho final de 2026. O teste de isolamento aplica 1% sem disponibilizar o arquivo de 2% e rejeita horários posteriores ao corte.

Corte	Largura original	Largura com piso	Afastamento
1%	0,70 p.p.	1,49 p.p.	$\pm$0,745 p.p.
2%	0,65 p.p.	3,74 p.p.	$\pm$1,872 p.p.

Largura é a distância total entre os extremos. Nos dois cortes, o maior erro histórico veio de 2018. A faixa de 2% ficou mais larga porque o erro naquele corte foi maior. Não impus suavização ou monotonicidade depois de ver esses números.

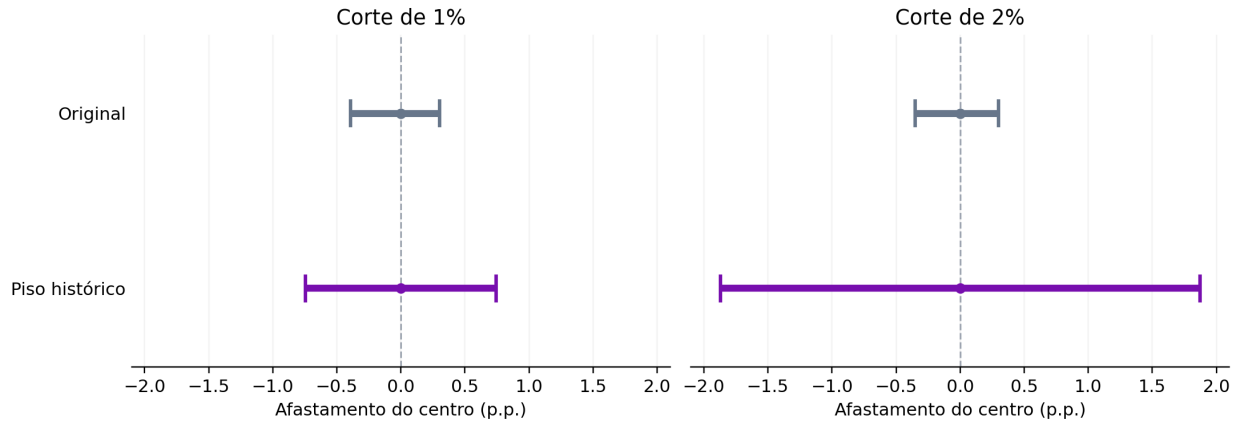


Figura 7. Afastamentos relativos ao centro congelado de cada corte. O zero do eixo é o centro do modelo, não zero por cento de votação.

9.3 O que a correção ainda não resolve

Tenho somente duas eleições históricas elegíveis na aplicação a 2026 e apenas uma na avaliação de 2022. **Não demonstrei cobertura de 95%.** Uma calibração conformal simples com somente duas eleições de calibração não produz um raio finito informativo nesse nível; a garantia usual também dependeria de intercambialidade, não estabelecida entre eleições. Referência: Angelopoulos e Bates.

Registrei o protocolo antes das contas desta rodada, mas escolhi as regras após conhecer o diagnóstico anterior. A comparação continua exploratória e retrospectiva, e 2022 já havia sido usada em outras partes do projeto.

O piso muda a extensão da faixa, sem reestimar coeficientes nem criar novos sorteios. Os 600/600 pertencem ao bootstrap original e não viraram probabilidades calibradas depois da correção. A distribuição com zero urnas permanece separada, condicionada aos priors; este backtest não valida automaticamente os 34,63%.

10. Como projetei o caminho da apuração

Prever o placar final exige estimar quantos votos ainda faltam para cada candidato. Prever a trajetória exige também estimar **a ordem em que esses votos aparecerão**.

Construí uma ordem hipotética com os horários municipais de 2022 e a cronologia das seções no primeiro turno de 2026. Em cada UF, alinhei o relógio histórico à fração já observada no corte de 0,9984% nacional; nas UFs sem seções observadas, usei o relógio nacional. Distribuí as pendências pelas caudas históricas e, dentro de cada município, usei a ordem do primeiro turno.

Fixei essa ordem e acumulei os votos previstos pelos 600 conjuntos de coeficientes, começando pelos votos já contados. As curvas mostram a média dos percentuais acumulados, e os resultados posteriores ao corte não entram como novas respostas para reajustá-las.

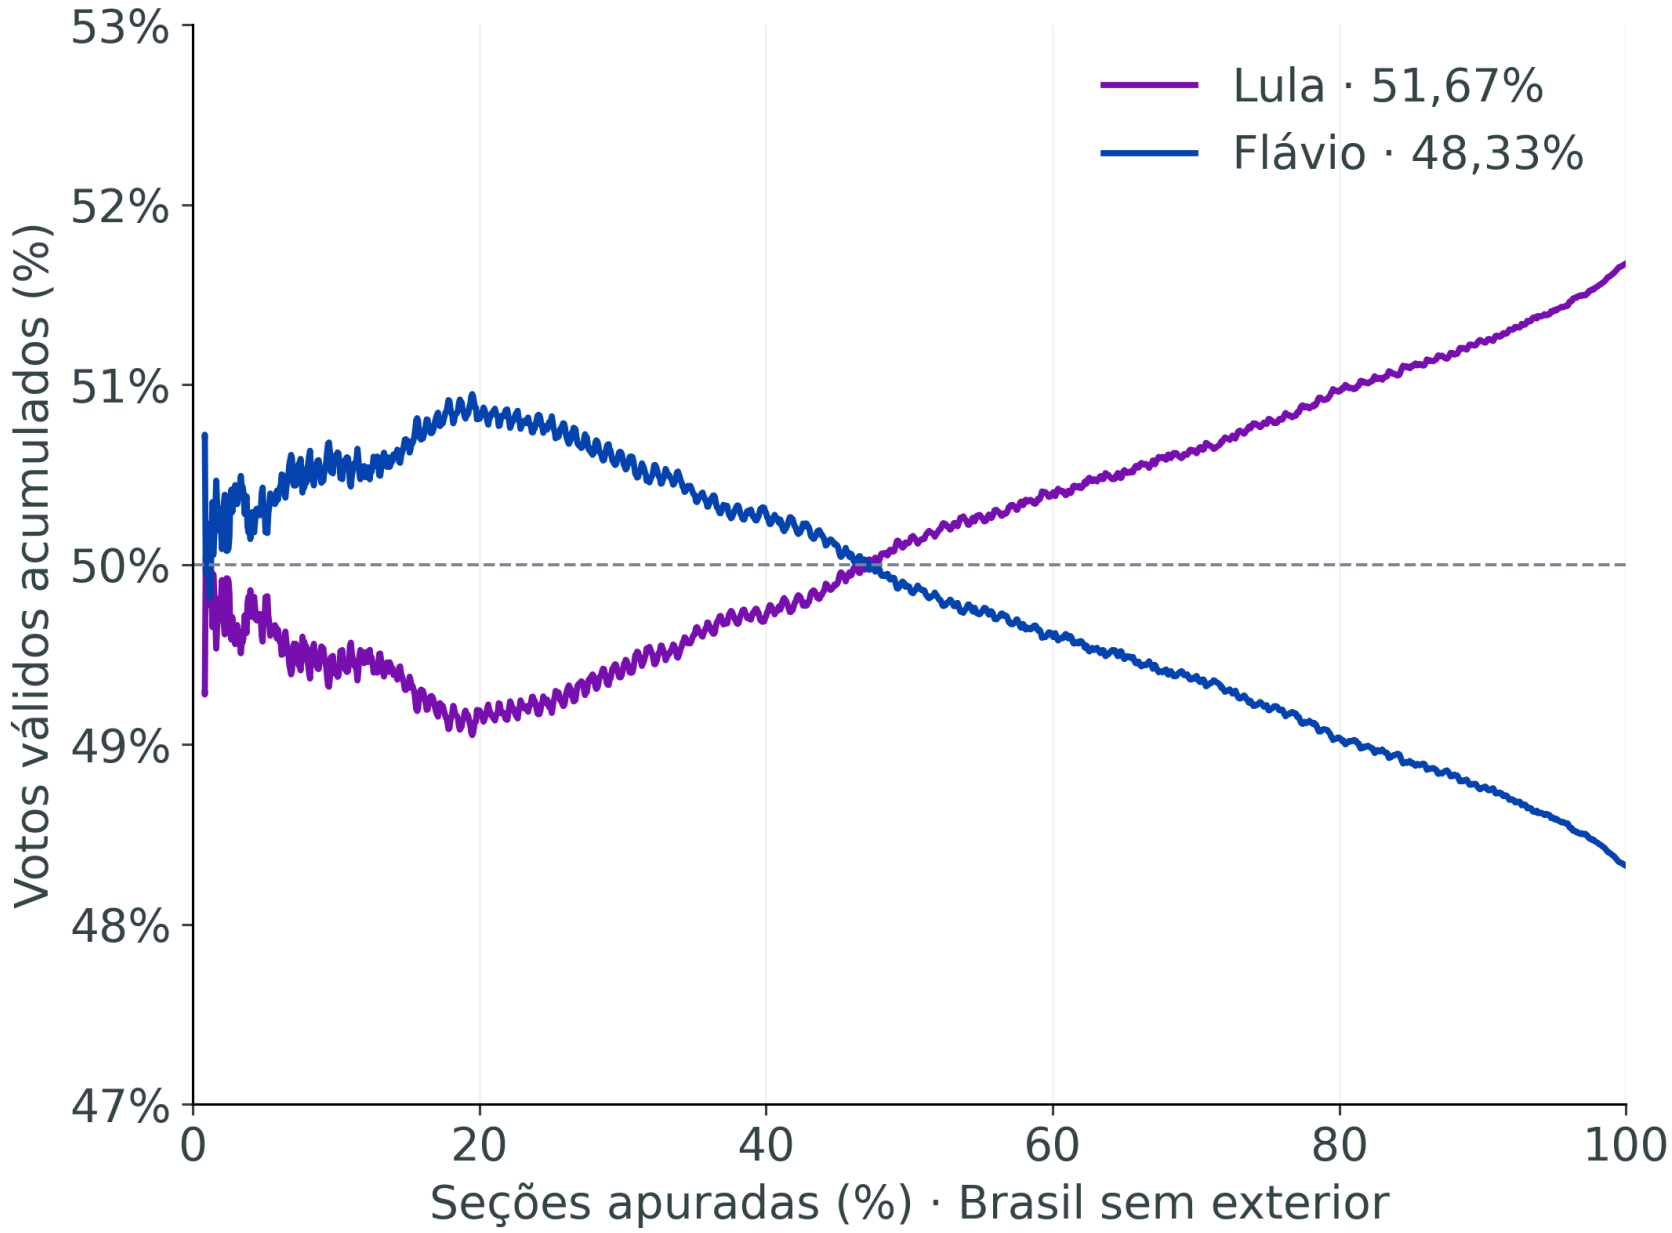


Figura 8. Trajetória projetada com o corte de 0,9984% nacional. O eixo mede seções domésticas: seu ponto inicial é 0,8452%. A ordem hipotética usa o ritmo de 2022 e a cronologia do primeiro turno; os pontos finais preservam as 600 reestimações por WLS sem prior do corte de menos de 1%.

Nessa ordem hipotética, a última passagem projetada de Lula à frente aparece perto de 47% das seções domésticas. O valor interpolado na grade é 47,48%. A trajetória termina em 51,67% para Lula e 48,33% para Flávio, como no resultado final previsto com o corte de menos de 1%.

Fixei em um as velocidades relativas dos relógios históricos entre UFs. O bloco ativo conhecido no corte tinha 28 segundos, insuficientes para a validação de velocidades com horizonte de dois minutos usada na análise anterior de 2%. Essa escolha foi registrada antes de calcular a curva; nenhum alvo de cruzamento entrou na ordenação.

Em cada um dos 600 cenários, o ponto final da trajetória coincide com a previsão congelada da regressão de 1%. A fila muda o caminho dos votos até esse ponto. A incerteza sobre a ordem de chegada não está incluída na dispersão dos coeficientes, e os tempos históricos auxiliares servem para ordenar as seções, sem fornecer horários de chegada calibrados.

O histórico de 2022 tem três papéis separados: junto com 2014 e 2018, informa a participação na simulação sem urnas; ajuda a ordenar as pendências na trajetória; e, junto com 2018, fornece erros históricos para o piso de incerteza. Os coeficientes com urnas continuam estimados apenas com o primeiro turno de 2026 e os resultados disponíveis no corte, sem pesquisa ou margem histórica de participação.

11. O que eu concluo deste exercício

O exercício mostra como uma especificação econométrica liga a composição observada do eleitorado a respostas ainda incompletas, produz uma previsão e torna suas hipóteses examináveis. Também separa problemas que exigem soluções diferentes: estimar os coeficientes, representar sua incerteza, extrapolar para seções pendentes e ordenar a chegada dos resultados.

O desempenho precisa ser lido à luz da reconstrução retrospectiva. Trabalhei com extratos finalizados, e filtrar pela primeira totalização não recupera necessariamente versões antigas de votos retificados. Também escolhi entre especificações com o resultado final já conhecido. Esse procedimento não equivale a uma previsão registrada ao vivo.

O backtest parcial acrescentou um diagnóstico concreto: a variação dos reajustes municipais não representou suficientemente todos os erros de extrapolação. O piso histórico é uma primeira proteção, ainda experimental. Mais sorteios não substituem mais eleições, arquivos históricos verificáveis e uma avaliação prospectiva. Continuo a investigação por região e em outros cargos.

Para quem quiser replicar

Deixei o código e os dados em um repositório público, com um README que explica a instalação e o passo a passo:

https://github.com/vr-rodrigues/regressao-eleitoral-quaest

O comando `python reproduzir.py --verificar` recalcula os coeficientes, gera as tabelas e os gráficos e confere os resultados com zero urnas e nos cortes de 1% e 2%. A versão enxuta recebe a ordem hipotética da trajetória como insumo; os votos previstos são recalculados com os novos ajustes.

O pacote complementar `replicar_piso_historico.zip`, que acompanha esta versão, reproduz a conta das faixas a partir dos erros históricos e afastamentos congelados. Ele não reestima os microdados; o repositório acima reproduz o exercício original.